

Analiza porównawcza wpływu kursu przygotowawczego na wyniki

Sprawozdanie 1

Martyna Pacyna 287440

Lena Rojecka 287460

1 Wstęp

Analizowany zbiór danych pochodzi z platformy Kaggle i dotyczy wyników egzaminacyjnych uczniów szkół średnich z trzech głównych przedmiotów: matematyki (math score), czytania (reading score) oraz pisanie (writing score). Zbiór składa się z 1000 obserwacji, z których każda opisuje pojedynczego ucznia za pomocą 8 cech. Jest to zestaw danych stworzony głównie w celach edukacyjnych. Głównym celem niniejszego sprawozdania jest przeprowadzenie analizy porównawczej rozkładów wyników egzaminacyjnych z matematyki w dwóch grupach uczniów: tych, którzy odbyli kurs przygotowawczy (358 uczniów), oraz tych, którzy tego nie zrobili (642 uczniów).

2 Analiza rozkładów przy pomocy metryk statystycznych

Średnia arytmetyczna. Wzór:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

n – liczebność próby,

x_i – i -ta obserwacja w zbiorze danych.

Ta średnia to średni wynik w grupie. Jeśli $\bar{x}$ dla grupy po kursie będzie większa niż dla grupy bez kursu, to może to znaczyć, że kurs podnosi ogólny poziom wiedzy studenta. Obliczono średnią arytmetyczną dla obu analizowanych grup.

Grupa po kursie przygotowawczym:

$$\bar{x} = \frac{1}{358} \sum_{i=1}^{358} x_i = 69.695530.$$

Grupa bez kursu przygotowawczego:

$$\bar{x} = \frac{1}{642} \sum_{i=1}^{642} x_i = 64.077881.$$

Średnia arytmetyczna dla wyników po kursie jest wyższa od średniej dla wyników bez kursu. Różnica ta nie jest duża, ale może wskazywać na pozytywną zależność między uczestnictwem w kursie a osiągniętymi wynikami.

Mediana. Wzór:

$$x_{med} = \begin{cases} x_{(\frac{n+1}{2})}, & \text{gdy } n \text{ jest nieparzyste,} \\ \frac{1}{2} \left(x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)} \right), & \text{gdy } n \text{ jest parzyste,} \end{cases}$$

n – liczebność próby,

x_i – i -ta uporządkowana obserwacja.

Mediana jest wartością środkową w uporządkowanym zbiorze danych, która dzieli go na dwie grupy. Oznacza to, że połowa obserwacji ma mniejsze lub równe wartości od mediany i analogicznie druga połowa ma niemniejsze wartości niż mediana. Obliczono medianę dla obu analizowanych grup.

Grupa po kursie przygotowawczym:

$$x_{med} = \frac{1}{2} \left(x_{(\frac{358}{2})} + x_{(\frac{358}{2}+1)} \right) = \frac{1}{2} (x_{(179)} + x_{(180)}) = 69.$$

Grupa bez kursu przygotowawczego:

$$x_{med} = \frac{1}{2} \left(x_{(\frac{642}{2})} + x_{(\frac{642}{2}+1)} \right) = \frac{1}{2} (x_{(321)} + x_{(322)}) = 64.$$

Wyższa mediana dla grupy uczestniczących w kursie przygotowawczym sugeruje, że te osoby osiągają wyższe przeciętne wyniki niż w grupie nieuczestniczących w kursie. Różnica median nie jest duża, ale sugeruje pozytywny wpływ na osiągnięte wyniki.

Średnia ucinana. Wzór:

$$\bar{x}_u = \frac{1}{n - 2k} \sum_{i=k+1}^{n-k} x_i$$

n – liczebność próby,

k – liczba odrzuconych obserwacji z każdej strony uporządkowanego zbioru,

x_i – i -ta uporządkowana obserwacja.

To miara statystyczna, na którą w porównaniu ze średnią arytmetyczną mniej wpływają wartości skrajne. Jeśli średnia ucinana niewiele się zmienia przy zwiększaniu k , oznacza to, że dane mają niewielkie wahania. W dalszej części pracy pokazano wykresy zależności średniej ucinanej od k , które przedstawiają wpływ liczby odrzucanych obserwacji na wynik. Obliczono średnie ucinane dla $k \approx 10\% \cdot n$ dla obu grup.

Grupa po kursie przygotowawczym, $k = 36$:

$$\bar{x}_u = \frac{1}{358 - 2 \cdot 36} \sum_{i=36+1}^{358-36} x_i = \frac{1}{286} \sum_{i=37}^{322} x_i = 69.853146.$$

Grupa bez kursu przygotowawczego, $k = 64$:

$$\bar{x}_u = \frac{1}{642 - 2 \cdot 64} \sum_{i=64+1}^{642-64} x_i = \frac{1}{514} \sum_{i=65}^{578} x_i = 64.437743.$$

Obie grupy są dość jednorodne, ponieważ w każdej z nich średnia ucinana jest bardzo zbliżona do średniej arytmetycznej. Oznacza to, że wartości skrajne nie wpływają znacząco na średni wynik z egzaminu, a średnia arytmetyczna dobrze opisuje rozkład wyników w obu grupach.

Średnia winsorowska. Wzór:

$$\bar{x}_w = \frac{1}{n} \left[(k+1)x_{(k+1)} + \sum_{i=k+2}^{n-k-1} x_i + (k+1)x_{(n-k)} \right]$$

n – liczebność próby,

k – liczba modyfikowanych obserwacji z każdej strony uporządkowanego zbioru,

x_i – i -ta uporządkowana obserwacja.

To miara statystyczna, na którą w porównaniu ze średnią arytmetyczną mniej wpływają wartości skrajne. Jeśli średnia winsorowska niewiele się zmienia przy zwiększaniu k , oznacza to, że dane mają niewielkie wahania. W dalszej części pracy pokazano wykresy zależności średniej winsorowskiej od k , które przedstawiają wpływ liczby modyfikowanych obserwacji na wynik. Obliczono średnie winsorowskie dla $k \approx 10\% \cdot n$ dla obu grup.

Grupa po kursie przygotowawczym, $k = 36$:

$$\bar{x}_w = \frac{1}{358} \left[(36+1)x_{(36+1)} + \sum_{i=36+2}^{358-36-1} x_i + (36+1)x_{(358-36)} \right] = 69.782122.$$

Grupa bez kursu przygotowawczego, $k = 64$:

$$\bar{x}_w = \frac{1}{642} \left[(64+1)x_{(64+1)} + \sum_{i=64+2}^{642-64-1} x_i + (64+1)x_{(642-64)} \right] = 64.350467.$$

Średnia winsorowska w obu grupach jest bardzo zbliżona do średniej arytmetycznej i ucinanej, co potwierdza brak znaczących wartości odstających. Jednocześnie nadal widać różnicę między grupami, co wskazuje, że uczniowie po kursie osiągają nieco wyższe wyniki niezależnie od sposobu liczenia średniej.

Kwartyle.

$Q2$ – mediana,

$Q1$ – mediana grupy obserwacji mniejszych od $Q2$,

$Q3$ – mediana grupy obserwacji większych od $Q2$.

Kwartyle dzielą zbiór na 4 grupy. Kwartył pierwszy ($Q1$) mówi o tym, że 25% danych ma wartości mniejsze lub równe $Q1$. Analogicznie kwartył trzeci ($Q3$) pokazuje od jakiej wartości 75% danych jest mniejsze lub równe. Wyznaczono $Q1, Q2, Q3$ dla obu analizowanych grup.

Grupa po kursie przygotowawczym:

$$Q1 = 60,$$

$$Q2 = 69,$$

$$Q3 = 79.$$

Grupa bez kursu przygotowawczego:

$$Q1 = 54,$$

$$Q2 = 64,$$

$$Q3 = 75.$$

Wszystkie obliczone kwartyle są nieco wyższe dla grupy uczniów po kursie przygotowawczym, co wskazuje na lepsze wyniki na całym rozkładzie, a nie tylko w jego wybranych fragmentach. Sugeruje to bardzo subtelna poprawę wyników po ukończeniu kursu.

IQR (rozstęp międzykwartylowy). Wzór:

$$IQR = Q3 - Q1$$

$Q1$ – pierwszy kwartyl,

$Q3$ – trzeci kwartyl.

Rozstęp międzykwartylowy opisuje rozrzut środkowych 50% danych, pozwala ocenić jak bardzo są skoncentrowane wokół mediany. Obliczono IQR dla obu analizowanych grup.

Grupa po kursie przygotowawczym:

$$IQR = Q3 - Q1 = 79 - 60 = 19.$$

Grupa bez kursu przygotowawczego:

$$IQR = Q3 - Q1 = 75 - 54 = 21.$$

Wartość IQR dla wyników uczniów po kursie przygotowawczym jest nieznacznie mniejsza niż drugiej grupy, co oznacza, że rozproszenie wyników w zakresie typowych wartości jest bardzo podobne w obu przypadkach. Typowe wyniki są nieco zróżnicowane, ale bez skrajnie dużego rozproszenia

Wariancja z próby. Wzór:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

n – liczebność próby,

x_i – i -ta obserwacja w zbiorze danych,

$\bar{x}$ – średnia arytmetyczna próby.

Wariancja określa jak bardzo wartości z danego zbioru różnią się od średniej arytmetycznej. Wysoka wariancja oznacza duże zróżnicowanie wyników, natomiast niska ich skupienie wokół średniej. Wyznaczono wariancję dla obu analizowanych grup.

Grupa po kursie przygotowawczym:

$$s^2 = \frac{1}{358-1} \sum_{i=1}^{358} (x_i - 69.695530)^2 = \frac{1}{357} \sum_{i=1}^{358} (x_i - 69.695530)^2 = 208.649335.$$

Grupa bez kursu przygotowawczego:

$$s^2 = \frac{1}{642-1} \sum_{i=1}^{642} (x_i - 64.077881)^2 = \frac{1}{641} \sum_{i=1}^{642} (x_i - 64.077881)^2 = 230.808277.$$

Różnica między wariancjami nie jest duża, natomiast możemy zaobserwować nieco niższą wartość dla próbki po kursie przygotowawczym. Sugeruje to mniejsze zróżnicowanie wyników, co za tym idzie, bardziej wyrównany poziom wiedzy studentów niż w grupie, która tego kursu nie wykonała.

Odchylenie standardowe. Wzór:

$$s = \sqrt{\frac{\sum (x_i - \bar{x})^2}{n - 1}}.$$

n – liczebność próby,

x_i – i -ta obserwacja w zbiorze danych,

$\bar{x}$ – średnia arytmetyczna próby.

Odchylenie standardowe, będące pierwiastkiem wariancji, określa rozrzut danych wokół średniej arytmetycznej. Wyznaczono odchylenie standardowe dla obu analizowanych grup.

Grupa po kursie przygotowawczym:

$$s = \sqrt{s^2} = \sqrt{208.649335} = 14.444699$$

Grupa bez kursu przygotowawczego:

$$s = \sqrt{s^2} = \sqrt{230.808277} = 15.192375$$

Różnica w odchyleniach standardowych jest bardzo niewielka. W grupie po kursie przygotowawczym zaobserwowano nieznacznie niższe odchylenie standardowe, co wskazuje na o nieco większą przewidywalność i stabilność wyników niż w grupie bez kursu.

Odchylenie przeciętne od wartości średniej. Wzór:

$$d = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|$$

n – liczebność próby,

x_i – i -ta obserwacja w zbiorze danych,

$\bar{x}$ – średnia arytmetyczna próby.

Odchylenie przeciętne od wartości średniej mówi, o ile średnio wartości ze zbioru danych się różnią od średniej arytmetycznej. Obliczono odchylenie przeciętne od wartości średniej dla obu analizowanych grup.

Grupa po kursie przygotowawczym:

$$d = \frac{1}{358} \sum_{i=1}^{358} |x_i - 69.695530| = 11.584282.$$

Grupa bez kursu przygotowawczego:

$$d = \frac{1}{642} \sum_{i=1}^{642} |x_i - 64.077881| = 12.010073.$$

Nieznacznie wyższa wartość odchylenia dla grupy bez kursu sugeruje, że wyniki odbiegają od średniej arytmetycznej o drobinę bardziej niż dla drugiej grupy. Różnica jest bardzo niewielka, dlatego efekt jest niewyraźny.

Współczynnik skośności (asymetrii). Wzór:

$$\alpha = \frac{n}{(n-1)(n-2)} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s} \right)^3$$

s – odchylenie standardowe z próby,

$\bar{x}$ – średnia arytmetyczna próby,

n – liczebność próby,

x_i – i -ta obserwacja w zbiorze danych.

Współczynnik skośności opisuje asymetrię rozkładu danych. Pozwala ocenić, czy w rozkładzie występuje przewaga wartości niskich lub wysokich. Obliczono współczynnik skośności dla obu analizowanych grup.

Grupa po kursie przygotowawczym:

$$\alpha = \frac{358}{(358-1)(358-2)} \sum_{i=1}^{358} \left(\frac{x_i - \bar{x}}{s} \right)^3 = \frac{179}{63546} \sum_{i=1}^{358} \left(\frac{x_i - 69.695530}{14.444699} \right)^3 = -0.147522.$$

Grupa bez kursu przygotowawczego:

$$\alpha = \frac{642}{(642-1)(642-2)} \sum_{i=1}^{642} \left(\frac{x_i - \bar{x}}{s} \right)^3 = \frac{321}{205120} \sum_{i=1}^{642} \left(\frac{x_i - 64.077881}{15.192375} \right)^3 = -0.328723.$$

Wartości współczynnika skośności dla obu analizowanych grup są ujemne, co oznacza lewostronną skośność. Większość obserwacji znajduje się przy wyższych wartościach. Wartość bezwzględna skośności bliska 0 dla grupy po kursie przygotowawczym wskazuje na rozkład bliski symetrycznemu. Troszkę większa dla drugiej grupy mówi o większej ilości niskich odstających wyników, ale ten rozkład również nie wykazuje dużej asymetrii.

Kurtoza. Wzór:

$$K = \frac{n-1}{(n-2)(n-3)} [(n+1)K_1 - 3(n-1)] + 3$$

$$K_1 = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4}{\left(\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \right)^2}$$

$\bar{x}$ – średnia arytmetyczna próby,

n – liczebność próby,

x_i – i -ta obserwacja w zbiorze danych.

Kurtoza to miara koncentracji uzyskanych wyników. Mówi czy i w jakim stopniu dane są skoncentrowane wokół średniej. Dla rozkładu normalnego kurtoza przyjmuje wartość 3, co stanowi punkt odniesienia przy interpretacji wyników. Wyznaczono kurtozę dla obu analizowanych grup.

Grupa po kursie przygotowawczym:

$$K_1 = \frac{\frac{1}{358} \sum_{i=1}^{358} (x_i - 69.695530)^4}{\left(\frac{1}{358} \sum_{i=1}^{358} (x_i - 69.695530)^2 \right)^2} = 2.821198.$$

$$K = \frac{358-1}{(358-2)(358-3)} [(358+1)K_1 - 3(358-1)] + 3 = 2.835624$$


Grupa bez kursu przygotowawczego:

$$K_1 = \frac{\frac{1}{642} \sum_{i=1}^{642} (x_i - 64.077881)^4}{\left(\frac{1}{642} \sum_{i=1}^{642} (x_i - 64.077881)^2 \right)^2} = 3.388875.$$

$$K = \frac{642-1}{(642-2)(642-3)} [(642+1)K_1 - 3(642-1)] + 3 = 3.401325$$


Drobna różnica w wartościach kurtozy dla obu grup wskazuje na nieznacznie odmienny kształt rozkładów. W obu przypadkach wartości pozostają w pobliżu poziomu charakterystycznego dla rozkładu normalnego. Wartość kurtozy nieco niższa od 3 dla grupy po kursie wskazuje na rzadszą obecność wartości odstających. Wartość nieco wyższa od 3 dla grupy bez kursu sugeruje częstsze pojawianie się wyników skrajnych.

3 Prezentacja rozkładów na wykresach




Rysunek 1: Histogramy ukazujące liczbę osób oraz punktację jaką uzyskały z testu końcowego dla grupy po kursie przygotowawczym (po lewej) oraz bez (po prawej).

Na wykresie widać, że niebieski wykres jest lekko przesunięty w prawą stronę, w porównaniu z czerwonym wykresem. Potwierdza to obliczenia oraz wnioski dotyczące średnich. Wychodzącą ze wzorów powyżej ujemną skośność w obu przypadkach potwierdzają zaprezentowane wykresy posiadające lewostronne ogony. Kształt rozkładu, scharakteryzowany przez kurtozę i skośność, sugeruje większą koncentrację wyników, w obu przypadkach, w wyższych zakresach wartości, co widoczne jest w większym zagęszczeniu danych po prawej stronie wykresu. Wskazano również modę, czyli w tym przypadku słupek najczęstszych wyników. Odczytując z wykresu dla grupy uczniów po kursie przygotowawczym moda wynosi $[67, 70)$ natomiast dla uczniów bez kursu $[60, 64)$. Dodatkowo, niezależnie od wykresu, wskazano pojedyncze najczęstsze wyniki. Dla grupy po kursie jest to 65 punktów zdobyte przez 16 osób oraz dla grupy bez kursu są to 62 punkty uzyskane przez 28 uczniów. Zarówno moda punktowa jak i przedziałowa są wyższe dla grupy osób, które odbyły kurs.




Rysunek 2: Histogramy (opisane powyżej) z nałożoną gęstością rozkładu normalnego (czerwona linia), której parametry (μ, σ^2) oszacowano na podstawie danych empirycznych jako średnią arytmetyczną oraz odchylenie standardowe z próby.

Krzywa normalna, w przypadku lewego wykresu, odwzorowuje ogólny kształt rozkładu, jednak nie oddaje w pełni większego zagęszczenia wyższych wyników. Widoczne są lekkie niedopasowania w ogonie po prawej stronie. Prawy wykres również wykazuje się umiarkowanym dopasowaniem do rozkładu normalnego. Histogram prezentuje bardziej wydłużony lewy ogon niż przewiduje to rozkład normalny. Zastosowanie modelu rozkładu normalnego do opisu uzyskanych wyników stanowi pewne uproszczenie. Przyjęcie tej krzywej teoretycznej pozwala na umiarkowanie precyzyjne oddanie charakteru obu analizowanych grup.



Rysunek 3: Wykresy pudełkowe z zaznaczonymi wartościami odstającymi oraz średnimi.

Prezentowany wykres pudełkowy pokazuje różnice między dwoma badanymi grupami. Zauważono, że uczestnicy kursu przygotowawczego osiągnęli wyższe wyniki z testu niż druga grupa uczniów. Najbardziej dostrzegalne są linie średnich wyników. Niebieska linia jest zdecydowanie wyżej niż linia czerwona, co potwierdza obliczenia. Niebieski boxplot jest krótszy niż różowy, co znajduje bezpośrednie potwierdzenie w wartościach wariancji oraz *IQR*. W grupie bez kursu wyniki są bardziej rozproszone. Zaobserwowano też długi dolny wąs oraz liczne wartości odstające, co wizualnie odpowiada ujemnej skośności rozkładu. Pokazuje to, że bez kursu przygotowawczego ryzyko uzyskania bardzo niskiego wyniku jest wyższe niż po zrobieniu kursu. Zauważono, że w grupie, która odbyła kurs, występujące minimalne wartości znajdują się wyżej niż odstające niskie wyniki grupy bez kursu. Dzięki temu nawet najslabsi uczniowie w grupie po kursie osiągają wyniki zbliżone do średniej grupy nieprzygotowanej. Nie obserwujemy też dużo wartości odstających.



Rysunek 4: Zależność średnich od parametru k dla dwóch grup: po kursie (po lewej) oraz bez kursu (po prawej).

Na podstawie wykresów wyciągnięto wnioski. Średnia ucinana jak i winsorowska na lewym wykresie początkowo rośnie wraz z k , co sugeruje, że pierwsze usuwane obserwacje to pojedyncze niskie wartości, które zaniżały obraz grupy po kursie. Na prawym wykresie ten początkowy wzrost jest bardziej stromy, co może oznaczać więcej bardzo niskich wyników w grupie bez kursu przygotowawczego.

4 Wnioski

Kurs przygotowawczy okazał się efektywny, co potwierdza wzrost wszystkich miar statystycznych, w tym średniej arytmetycznej, ucinanej oraz mediany. Grupa po przygotowaniu stała się bardziej jednorodna, co obrazuje mniejsza wariancja. Kluczowym efektem szkolenia była redukcja wyników skrajnie niskich i eliminacja wartości odstających, które w grupie kontrolnej tworzyły lewy ogon. Wykresy pudełkowe potwierdzają statystyczną istotność tych różnic, a kurtoza bliska wartości 3 dowodzi, że oba rozkłady zachowują stabilny charakter zbliżony do normalnego. Rozkłady te wydawały się bardzo zbliżone, jednak po głębszej analizie matematycznej kurs przygotowawczy podnosząc ogólny poziom wiedzy obniżył ryzyko egzaminacyjnej porażki.