

Analiza porównawcza wpływu kursu przygotowawczego na wyniki

Sprawozdanie 1

Martyna Pacyna 287440

Lena Rojecka 287460

1 Wstęp

2 Testowanie hipotezy dotyczącej średniej

W tym zadaniu należało wykorzystać dane przekazane przez prowadzącą, aby przeprowadzić testowanie hipotezy zerowej $H_0 : \mu = 1.5$ przeciwko trzem hipotezom alternatywnym. Najpierw wyznaczymy wartość statystyki testowej. To taka funkcja próby, na podstawie której wnioskujemy się o odrzuceniu lub nie hipotezy statystycznej. Pierwsze porównanie przeprowadzimy przez wyznaczenie hipotezy testowej. Użyjemy statystyki testowej Z , ponieważ mamy do czynienia z próbami o rozkładzie normalnym, o dużej wielkości oraz ze znanym odchyleniem standardowym. Wyliczamy go z poniższego wzoru:

$$Z = \frac{\bar{X} - \mu_0}{\sigma / \sqrt{n}}$$

Gdzie:

- $\bar{X}$ – średnia z danych (wyliczona z pakietu numpy dla naszych danych wynosi ≈ 1.45546),
- $\mu_0 = 1.5$ – wartość z hipotezy zerowej,
- $\sigma = 0.2$ – sztywna wartość z treści zadania,
- n – liczba elementów (w naszym przypadku 1000).

$$SE = \frac{\sigma}{\sqrt{n}}$$

Obliczamy więc, że

$$Z = \frac{\bar{X} - \mu_0}{\sigma / \sqrt{n}} = \frac{1.45546 - 1.5}{0.2 / \sqrt{1000}} \approx \frac{-0.04}{0,00632} \approx -7.04$$



$$SE = \frac{\sigma}{\sqrt{n}} = \frac{0.2}{\sqrt{1000}} \approx 0.0063$$


Dla naszych danych $Z \approx -7.04$ co stanowi bardzo rzadki wynik. Obliczyliśmy również błąd standardowy (który jest mianownikiem równania powyżej), z którego wychodzi nam $SE = 0.0063$. Wynik taki wyszedł między innymi dlatego, że nasza średnia z próby $\bar{X} = 1.455$. Jest to wynik mniejszy niż nasz oczekiwany (1.5). Nasza próba jest też bardzo duża, bo stanowi 1000 elementów. Przy tak gigantycznej próbie, nawet mała różnica od zakładanej średniej staje się znacząca. Taki wynik oznacza, że nasza próba jest bardzo czuła i precyzyjna.

Kolejnym krokiem będzie określenie obszaru krytycznego dla każdego przypadku. Jeśli hipoteza zerowa mówi o tym, że coś jest różne, to obszar krytyczny jest dwustronny i zaznaczamy zarówno prawą jak i lewą końcówkę rozkładu. Jeśli hipoteza alternatywna jest sformułowana jako mniejsze lub większe, to zaznaczamy obszar odrzuceń albo z prawej albo z lewej strony.

Następnie dla każdej hipotezy alternatywnej obliczymy p-value, czyli wartość p. Jest to prawdopodobieństwo otrzymania wyników równie skrajnych lub jeszcze bardziej skrajnych niż uzyskane w badaniu, przy założeniu że hipoteza zerowa jest prawdziwa. Kolokwialnie mówiąc, jest to "wielkość naszego ogona", którego widać na wykresie. Jest to alternatywny sposób podejmowania decyzji w testowaniu hipotez. Decyzja na podstawie wartości p jest podejmowana przez porównanie wartości p z poziomem istotności α . Jeśli p value $\leq \alpha$ odrzucamy hipotezę zerową. Wartość p można interpretować jako najmniejszy poziom istotności, przy którym moglibyśmy odrzucić H_0 .

Zacznijmy od przeanalizowania hipotezy alternatywnej [$H_1: \mu \neq 1.5$]. Hipoteza alternatywna stwierdza, że badany parametr różni się od wartości określonej w hipotezie zerowej. W tym przypadku obszar krytyczny znajduje się w obu ogonach rozkładu statystyki testowej. Odrzucamy H_0 jeśli wartość statystyki testowej jest ekstremalnie duża lub ekstremalnie mała. W tym przypadku granica lewostronna była liczona do poziomu $\alpha/2$, a prawostronna $1 - \alpha/2$ za pomocą funkcji ppf wbudowanej w pythonie.





W tym przypadku granice były równe kolejno dla poziomu istotności:

- $\alpha = 0.01$
granica lewostronna -2.57, granica prawostronna 2.57
- $\alpha = 0.05$
granica lewostronna -1.95, granica prawostronna 1.95
- $\alpha = 0.1$
granica lewostronna -1.64, granica prawostronna 1.64

Dla testu dwustronnego, p -wartość definiujemy jako

$$p = P(|Z| \geq |Z_{\text{obs}}|)$$

Wykorzystując własność wartości bezwzględnej, prawdopodobieństwo to rozbija się na sumę dwóch skrajnych ogonów rozkładu, natomiast z racji idealnej symetrii gęstości rozkładu normalnego, możemy zapisać to równanie za pomocą jednego ogona pomnożonego przez dwa. $F(x)$:

$$p = 2 \cdot P(Z \leq Z_{\text{obs}}) = 2 \cdot F(Z_{\text{obs}})$$

. U nas $Z_{\text{obs}} = -7.04$. Podstawiając wartość statystyki testowej do powyższego wzoru, otrzymujemy wyrażenie za pomocą całki gęstości prawdopodobieństwa rozkładu $N(0, 1)$:

$$p = 2 \cdot \int_{-\infty}^{-7.04} \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt$$




Wartość dystrybucyjnej dla tego punktu wynosi:

$$F(-7.04) \approx 9.61 \cdot 10^{-13}$$

$$p - \text{value} = 2 \cdot (9.61 \cdot 10^{-13}) \approx 1.92 \cdot 10^{-12} \approx 0.00000000000192$$

Interpretacja: Im większy mamy poziom istotności α , tym większe pole ma obszar krytyczny. Wartość p jest bardzo bliska zeru. Oznacza to, że prawie z całą pewnością możemy stwierdzić, że nasza hipoteza alternatywna jest prawdziwa i możemy odrzucić hipotezę zerową.

Kolejną hipotezą alternatywną jest hipoteza $[H_1: \mu > 1.5]$. Hipoteza alternatywna stwierdza, że badany parametr jest większy niż wartość określona w hipotezie zerowej. Obszar krytyczny znajduje się tylko w prawym ogonie rozkładu. Odrzucamy H_0 , jeśli wartość statystyki testowej jest ekstremalnie duża.



W tym przypadku rozpatrujemy jedynie granice prawostronną. Kolejno dla poziomu istotności:

- $\alpha = 0.01$
granica prawostronna 2.32
- $\alpha = 0.05$
granica prawostronna 1.64
- $\alpha = 0.1$
granica prawostronna 1.28

Dla testu prawostronnego, p-wartość definiujemy jako:

$$p = P(Z \geq Z_{\text{obs}})$$

Za pomocą dystrybuanty $F(x)$, która domyślnie mierzy pole od lewej strony, prawdopodobieństwo prawego ogona wyrażamy jako:

$$p = 1 - F(Z_{\text{obs}})$$

Podstawiając ujemną wartość statystyki testowej do wzoru, otrzymujemy:

$$p = 1 - F(-7.04)$$

. Wyrażając to za pomocą całki z funkcji gęstości prawdopodobieństwa rozkładu $N(0, 1)$:

$$p = \int_{-7.04}^{+\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt$$

Ponieważ punkt -7.04 leży ekstremalnie daleko na lewym ogonie, pole na lewo od niego ($F(-7.04)$) jest bliskie zeru. Wobec tego pole na prawo od niego obejmuje niemal cały wykres rozkładu:




$$F(-7.04) \approx 9.61 \cdot 10^{-13}$$

Odejmując tę wartość od jedności, otrzymujemy ostateczny wynik:

$$p - \text{value} = 1 - 9.61 \cdot 10^{-13} \approx 0.99999999999904$$

Interpretacja: Zwiększanie poziomu istotności alpha zwiększa obszar krytyczny dla obserwacji. Wartość p jest bardzo bliska 1. Oznacza to, że prawie z całą pewnością możemy stwierdzić, że nasze μ nie będzie większe od 1.5. Tym razem odrzucamy hipotezę alternatywną, a zostajemy przy zerowej.

Ostatnią hipotezą alternatywną, którą będziemy analizować jest hipoteza $[H_1: \mu < 1.5]$. Hipoteza ta stwierdza, że badany parametr jest mniejszy niż wartość określona w hipotezie zerowej. Obszar krytyczny znajduje się tylko w lewym ogonie rozkładu. Odrzucamy H_0 jeśli wartość statystyki testowej jest ekstremalnie mała.



W tym przypadku rozpatrujemy jedynie granice lewostronną. Kolejno dla poziomu istotności:

- $\alpha = 0.01$
granica lewostronna -2.32
- $\alpha = 0.05$
granica lewostronna -1.64
- $\alpha = 0.1$
granica lewostronna -1.28

Dla testu lewostronnego, p -wartość definiujemy jako:

$$p = P(Z \leq Z_{\text{obs}})$$

Za pomocą dystrybuanty $F(x)$, która domyślnie mierzy pole pod wykresem od skrajnej lewej strony aż do zadanego punktu, prawdopodobieństwo lewego ogona wyrażamy bezpośrednio jako:

$$p\text{-wartość} = F(Z_{\text{obs}})$$

Podstawiając ujemną wartość statystyki testowej do wzoru, otrzymujemy:

$$p = F(-7.04)$$

Wyrażając to za pomocą całki z funkcji gęstości prawdopodobieństwa rozkładu $N(0, 1)$:

$$p = \int_{-\infty}^{-7.04} \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt$$

Ponieważ punkt -7.04 leży ekstremalnie daleko na lewym ogonie, pole na lewo od niego (czyli dokładnie nasza dystrybuanta $F(-7.04)$) obejmuje jedynie mikroskopijny skrawek początku wykresu:

$$F(-7.04) \approx 9.61 \cdot 10^{-13}$$

W tym przypadku nie odejmujemy wartości od jedności, ponieważ interesuje nas wyłącznie obszar lewostronny. Otrzymujemy ostateczny wynik:

$$p\text{-value} = 9.61 \cdot 10^{-13} \approx 0.00000000000096$$


Interpretacja: Wartość p jest bardzo bliska 0. Oznacza to, że prawie z całą pewnością możemy stwierdzić, że nasze μ będzie mniejsze od 1.5. Tym razem odrzucamy hipotezę zerową, a zostajemy przy alternatywnej. Możemy też zauważyć, że rozkład ten jest symetryczny do rozkładu prawostronnego, jeśli chodzi o obszary krytyczne.

Wnioski ogólne: Zwiększanie poziomu istotności, będące równoznaczne ze zmniejszaniem poziomu ufności, poszerza obszar krytyczny i ułatwia odrzucenie hipotezy zerowej. W odwrotnej sytuacji, gdy rośnie poziom ufności a maleje istotność, obszar krytyczny się kurczy, przez co odrzucenie hipotezy zerowej wymaga znacznie silniejszych dowodów. Nasze obliczenia są prawidłowe, ponieważ średnia empiryczna wyszła około 1.45, co potwierdziły nam nasze testy p -value.

3 Wyznaczanie błędów testowych dla testowania średniej

Błąd I rodzaju

Błąd I rodzaju jest prawdopodobieństwem odrzucenia hipotezy zerowej, gdy jest ona prawdziwa. Jego teoretyczna wartość jest równa poziomowi istotności α .



Wykres pudełkowy przedstawia porównanie empirycznych, czyli uzyskanych w drodze symulacji komputerowej, wartości błędu I rodzaju z ich wartościami teoretycznymi dla trzech różnych poziomów istotności. Każde z trzech pionowych pudełek reprezentuje rozkład stu otrzymanych wyników symulacji, co pozwala ocenić stabilność i poprawność skonstruowanego testu statystycznego.

Główna, prostokątna część każdego wykresu, zwana pudełkiem, obejmuje tak zwany rozstęp międzykwartyłowy, w którym skupia się dokładnie połowa wszystkich uzyskanych z symulacji wartości. Pozioma, pomarańczowa kreska przebiegająca przez środek tego pudełka to mediana, która wyznacza wartość środkową całego zbioru danych i pokazuje, wokół jakiego punktu najczęściej oscylowały wyniki symulacji. Pionowe linie wychodzące w górę i w dół z pudełka, nazywane wąsami, wyznaczają zasięg typowych rezultatów i pokazują zakres, w jakim mieści się większość pozostałych wyników. Pojedyncze kółka widoczne na samych końcach, znajdujące się poza zasięgiem wąsów, to wartości odstające, które reprezentują rzadkie, skrajne przypadki losowe powstałe w wyniku naturalnej zmienności generatora liczb. Poziome, czerwone linie przerywane ciągnące się przez całą szerokość wykresu pokazują idealne wartości teoretyczne, z którymi porównujemy nasze symulacje.

Z wykresu jasno wynika, że mediany niemal idealnie pokrywają się z czerwonymi liniami przerywanymi, co stanowi ostateczny dowód na to, że test został zaprogramowany prawidłowo. Ponieważ wyniki symulacji komputerowej tak precyzyjnie skupiają się wokół założeń teoretycznych, wykres ten potwierdza, że rzeczywiste prawdopodobieństwo popełnienia błędu I rodzaju w naszym teście jest dokładnie równe założonemu poziomowi istotności alfa.

Błąd II rodzaju

Błąd II rodzaju jest prawdopodobieństwem nieodrzućcenia fałszywej hipotezy zerowej. Jego wartość zależy między innymi od odległości parametru rzeczywistego od wartości określonej w hipotezie zerowej.

μ	błąd II rodzaju
Test dwustronny	
1,47	0,001
1,48	0,110
1,49	0,638
1,51	0,649
1,52	0,092
1,53	0,002
Test lewostronny	
1,47	0,000
1,48	0,065
1,49	0,565
Test prawostronny	
1,51	0,549
1,52	0,063
1,53	0,001

Interpretacja: We wszystkich trzech testach widać wyraźną prawidłowość – im wartość rzeczywista μ leży bliżej wartości określonej w hipotezie zerowej (1.5), tym prawdopodobieństwo popełnienia błędu II rodzaju jest większe. Dla wartości najbardziej oddalonych, takich jak 1.47 czy 1.53, błąd ten spada niemal do zera (0.000 lub 0.001), co oznacza, że test niemal za każdym razem prawidłowo odrzuca fałszywą hipotezę zerową. Z kolei dla wartości leżących bardzo blisko (1.49 oraz 1.51) ryzyko niewykrycia różnicy gwałtownie rośnie, osiągając najwyższe wartości (odpowiednio 0.638 i 0.649 dla testu dwustronnego).

Analiza wyników dla tych samych wartości parametru μ pokazuje, że testy jednostronne charakteryzują się mniejszym błędem II rodzaju niż test dwustronny. Przykładowo, dla $\mu = 1.49$ błąd w teście dwustronnym wynosi 0.638, podczas gdy w teście lewostronnym spada do 0.565. Podobnie dla $\mu = 1.51$ test prawostronny daje błąd 0.549 w porównaniu do 0.649 w teście dwustronnym. Wynika to z faktu, że w testach jednostronnych cała strefa odrzucenia skupiona jest po jednej stronie, przez co test jest bardziej czuły na zmiany zachodzące w tym konkretnym kierunku i rzadziej popełnia błąd polegający na przyjęciu nieprawdziwej hipotezy zerowej.

Moc testu

Moc testu jest prawdopodobieństwem poprawnego odrzucenia fałszywej hipotezy zerowej i przyjęcia prawdziwej hipotezy alternatywnej. Oblicza się ją ze wzoru:

$$\text{Moc testu} = 1 - \beta,$$

gdzie β oznacza błąd II rodzaju. Moc testu obliczona dla każdej wartości jest przedstawiona w tabelce poniżej.

Test dwustronny		
μ	błąd II rodzaju	Moc testu
1,47	0,001	0,999
1,48	0,110	0,890
1,49	0,638	0,362
1,51	0,649	0,351
1,52	0,092	0,908
1,53	0,002	0,998
Test lewostronny		
1,47	0,000	1,000
1,48	0,065	0,935
1,49	0,565	0,435
Test prawostronny		
1,51	0,549	0,451
1,52	0,063	0,937
1,53	0,001	0,999

Interpretacja: Zdolność testu do wykrycia fałszywości hipotezy zerowej drastycznie rośnie, gdy rzeczywista średnia oddala się od wartości hipotetycznej. Dla punktów skrajnych, takich jak 1.47 i 1.53, moc testu osiąga niemal maksymalną wartość równą 1 (lub 0.999), co oznacza, że przy próbie wielkości $n = 1000$ test jest perfekcyjnie czuły i wykryje nawet tak małe przesunięcia średniej. Największą trudność test ma z identyfikacją wartości położonych najbliżej centrum (1.49 i 1.51), wykazując niską skuteczność detekcji. Porównując wyniki dla tych samych punktów (np. dla $\mu = 1.49$ oraz $\mu = 1.51$), można zauważyć przewagę testów jednostronnych nad testem dwustronnym. Dla $\mu = 1.49$ test dwustronny ma moc wynoszącą tylko 0.362, podczas gdy dedykowany test lewostronny osiąga moc 0.435. Z kolei dla $\mu = 1.51$ test prawostronny wykazuje moc 0.451 w porównaniu do 0.351 dla testu dwustronnego.