

Analiza porównawcza wpływu kursu przygotowawczego na wyniki

Sprawozdanie 1

Martyna Pacyna 287440

Lena Rojecka 287460

1 Wstęp

Analizowany zbiór danych pochodzi z platformy Kaggle i dotyczy wyników egzaminacyjnych uczniów szkół średnich z trzech głównych przedmiotów: matematyki (math score), czytania (reading score) oraz pisania (writing score). Zbiór składa się z 1000 obserwacji, z których każda opisuje pojedynczego ucznia za pomocą 8 cech. Jest to zestaw danych stworzony głównie w celach edukacyjnych. Głównym celem niniejszego sprawozdania jest przeprowadzenie analizy porównawczej wyników egzaminacyjnych z matematyki w dwóch grupach uczniów: tych, którzy odbyli kurs przygotowawczy (358 uczniów), oraz tych, którzy go nie posiadali (642 uczniów).

2 Analiza rozkładów przy pomocy metryk statystycznych

Średnia arytmetyczna. Wzór:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

n – liczebność próby,

x_i – i -ta obserwacja.

Ta średnia to średni wynik w grupie. Jeśli $\bar{x}$ dla grupy po kursie będzie większa niż dla grupy bez kursu, to kurs będzie podnosił ogólny poziom wiedzy studenta.

Mediana. Wzór:

$$x_{med} = \begin{cases} x_{(\frac{n+1}{2})}, & \text{gdy } n \text{ jest nieparzyste,} \\ \frac{1}{2} \left(x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)} \right), & \text{gdy } n \text{ jest parzyste,} \end{cases}$$

n – liczebność próby,

x_i – i -ta uporządkowana obserwacja.

Średnia ucinana. Wzór:

$$\bar{x}_u = \frac{1}{n-2k} \sum_{i=k+1}^{n-k} x_i$$

n – liczebność próby,

k – liczba odrzuconych obserwacji z każdej strony uporządkowanego zbioru,

x_i – i -ta uporządkowana obserwacja.

To miara statystyczna, która zmniejsza wpływ wartości skrajnych poprzez pozbycie się ich. Pozwala ocenić, czy dane są jednorodne oraz jak bardzo wyniki odstające wpływają na średnią. Jeśli średnia ucinana niewiele się zmienia przy zwiększaniu k , oznacza to, że dane mają niewielkie wahania. W dalszej części pracy pokazano wykresy zależności średniej ucinanej od k , które przedstawiają wpływ liczby odrzucanych obserwacji na wynik.

Obliczono średnie ucinane dla $k \approx 10\% \cdot n$ dla obu grup:

Grupa po kursie przygotowawczym, $k = 36$:

$$\bar{x}_u = \frac{1}{358 - 2 \cdot 36} \sum_{i=36+1}^{358-36} x_i = \frac{1}{286} \sum_{i=37}^{322} x_i = 69.853146$$

Grupa bez kursu przygotowawczego, $k = 64$:

$$\bar{x}_u = \frac{1}{642 - 2 \cdot 64} \sum_{i=64+1}^{642-64} x_i = \frac{1}{514} \sum_{i=65}^{578} x_i = 64.437743$$

Obie grupy są dość jednorodne, ponieważ w każdej z nich średnia ucinana jest bardzo zbliżona do średniej arytmetycznej. Oznacza to, że wartości skrajne nie wpływają znacząco na średni wynik z egzaminu, a średnia arytmetyczna dobrze opisuje rozkład wyników w obu grupach.

Średnia winsorowska. Wzór:

$$\bar{x}_w = \frac{1}{n} \left[(k+1)x_{(k+1)} + \sum_{i=k+2}^{n-k-1} x_i + (k+1)x_{(n-k)} \right]$$

n – liczebność próby,

k – liczba modyfikowanych obserwacji z każdej strony uporządkowanego zbioru,

x_i – i -ta uporządkowana obserwacja.

To miara statystyczna, która ogranicza wpływ wartości skrajnych poprzez ich zastąpienie najbliższymi wartościami z pozostałej części danych. Pozwala to ocenić, czy dane są jednorodne oraz jak bardzo wyniki odstające wpływają na średnią. Jeśli średnia winsorowska niewiele się zmienia przy zwiększaniu k , oznacza to, że dane mają niewielkie wahania. W dalszej części pracy pokazano wykresy zależności średniej winsorowskiej od k , które przedstawiają wpływ liczby modyfikowanych obserwacji na wynik.

Obliczono średnie winsorowskie dla $k \approx 10\% \cdot n$ dla obu grup:

Grupa po kursie przygotowawczym, $k = 36$:

$$\bar{x}_w = \frac{1}{358} \left[(36+1)x_{(36+1)} + \sum_{i=36+2}^{358-36-1} x_i + (36+1)x_{(358-36)} \right] = 69.782122$$

Grupa bez kursu przygotowawczego, $k = 64$:

$$\bar{x}_w = \frac{1}{642} \left[(64+1)x_{(64+1)} + \sum_{i=64+2}^{642-64-1} x_i + (64+1)x_{(642-64)} \right] = 64.350467$$

Średnia winsorowska w obu grupach jest bardzo zbliżona do średniej arytmetycznej i ucinanej, co potwierdza brak znaczących wartości odstających. Jednocześnie nadal widać różnicę między grupami, co wskazuje, że uczniowie po kursie osiągają wyższe wyniki niezależnie od sposobu liczenia średniej.

Kwartyle.

robie<3

IQR (rozstęp międzykwartylowy). Wzór:

$$IQR = Q3 - Q1$$

$Q1$ – pierwszy kwartyl,

$Q3$ – trzeci kwartyl.

Wariancja z próby. Wzór:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

n – liczebność próby,

x_i – i -ta obserwacja w zbiorze danych,

$\bar{x}$ – średnia arytmetyczna próby.

Odchylenie standardowe. Wzór:

$$s = \sqrt{\frac{\sum (x_i - \bar{x})^2}{n-1}}.$$

n – liczebność próby,

x_i – i -ta obserwacja w zbiorze danych,

$\bar{x}$ – średnia arytmetyczna próby.

Odchylenie przeciętne od wartości średniej. Wzór:

$$d = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|$$

n – liczebność próby,

x_i – i -ta obserwacja w zbiorze danych,

$\bar{x}$ – średnia arytmetyczna próby.

Współczynnik zmienności. Wzór:

$$\nu = \frac{s}{\bar{x}} \cdot 100\%$$

s – odchylenie standardowe z próby,

$\bar{x}$ – średnia arytmetyczna próby.

Współczynnik skośności (asymetrii). Wzór:

$$\alpha = \frac{n}{(n-1)(n-2)} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s} \right)^3$$


s – odchylenie standardowe z próby,
 $\bar{x}$ – średnia arytmetyczna próby,
 n – liczebność próby,
 x_i – i-ta obserwacja w zbiorze danych,


Kurtoza. Wzór: NIE WIEM CO Z TYM DROGIM SZALONYM WZOREM NA K

$$K_1 = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4}{\left(\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2\right)^2}$$

$\bar{x}$ – średnia arytmetyczna próby,
 n – liczebność próby,
 x_i – i-ta obserwacja w zbiorze danych,

3 Prezentacja rozkładów na wykresach





Rysunek 1: Zależność średnich od parametru k dla dwóch grup: po kursie (po lewej) oraz bez kursu (po prawej).

Na podstawie wykresów wyciągnięto wnioski. Średnia arytmetyczna jest wyższa od mediany w obu przypadkach, co mówi o dużej ilości wysokich wyników (rozkład prawostronnie skośny). Różnica między nimi w przypadku lewego wykresu wynosi 0.695530, co wskazuje na lekką asymetrię, natomiast prawego 0.077881, co jest mniejszą różnicą i sugeruje bardziej symetryczny rozkład. Pomarańczowa linia na lewym wykresie początkowo rośnie wraz z k , co sugeruje, że pierwsze usuwane obserwacje to pojedyncze niskie wartości, które zaniżały obraz grupy po kursie. Na prawym wykresie ten początkowy wzrost jest bardziej stromy, co może oznaczać więcej "niepowodzeń" (bardzo niskich wyników) w grupie bez przygotowania.

4 Wnioski