

Analiza porównawcza wpływu kursu przygotowawczego na wyniki

Sprawozdanie 1

Martyna Pacyna 287440

Lena Rojecka 287460

1 Wstęp

Analizowany zbiór danych pochodzi z platformy Kaggle i dotyczy wyników egzaminacyjnych uczniów szkół średnich z trzech głównych przedmiotów: matematyki (math score), czytania (reading score) oraz pisanie (writing score). Zbiór składa się z 1000 obserwacji, z których każda opisuje pojedynczego ucznia za pomocą 8 cech. Jest to zestaw danych stworzony głównie w celach edukacyjnych. Głównym celem niniejszego sprawozdania jest przeprowadzenie analizy porównawczej wyników egzaminacyjnych z matematyki w dwóch grupach uczniów: tych, którzy odbyli kurs przygotowawczy (358 uczniów), oraz tych, którzy go nie posiadali (642 uczniów).

2 Analiza rozkładów przy pomocy metryk statystycznych

Średnia arytmetyczna. Wzór:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

n – liczebność próby,

x_i – i -ta obserwacja.

Ta średnia to średni wynik w grupie. Jeśli $\bar{x}$ dla grupy po kursie będzie większa niż dla grupy bez kursu, to kurs będzie podnosił ogólny poziom wiedzy studenta.

Mediana. Wzór:

$$x_{med} = \begin{cases} x_{(\frac{n+1}{2})}, & \text{gdy } n \text{ jest nieparzyste,} \\ \frac{1}{2} \left(x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)} \right), & \text{gdy } n \text{ jest parzyste,} \end{cases}$$

n – liczebność próby,

x_i – i -ta uporządkowana obserwacja.

Średnia ucinana. Wzór:

$$\bar{x}_u = \frac{1}{n-2k} \sum_{i=k+1}^{n-k} x_i$$

n – liczebność próby,

k – liczba odrzuconych obserwacji z każdej strony uporządkowanego zbioru,

x_i – i -ta uporządkowana obserwacja.

To miara statystyczna, która zmniejsza wpływ wartości skrajnych poprzez pozbycie się ich. Pozwala ocenić, czy dane są jednorodne oraz jak bardzo wyniki odstające wpływają na średnią. Jeśli średnia ucinana niewiele się zmienia przy zwiększaniu k , oznacza to, że dane mają niewielkie wahania. W dalszej części pracy pokazano wykresy zależności średniej ucinanej od k , które przedstawiają wpływ liczby odrzucanych obserwacji na wynik.

Obliczono średnie ucinane dla $k \approx 10\% \cdot n$ dla obu grup:

Grupa po kursie przygotowawczym, $k = 36$:

$$\bar{x}_u = \frac{1}{358 - 2 \cdot 36} \sum_{i=36+1}^{358-36} x_i = \frac{1}{286} \sum_{i=37}^{322} x_i = 69.853146$$

Grupa bez kursu przygotowawczego, $k = 64$:

$$\bar{x}_u = \frac{1}{642 - 2 \cdot 64} \sum_{i=64+1}^{642-64} x_i = \frac{1}{514} \sum_{i=65}^{578} x_i = 64.437743$$

Obie grupy są dość jednorodne, ponieważ w każdej z nich średnia ucinana jest bardzo zbliżona do średniej arytmetycznej. Oznacza to, że wartości skrajne nie wpływają znacząco na średni wynik z egzaminu, a średnia arytmetyczna dobrze opisuje rozkład wyników w obu grupach.

Średnia winsorowska. Wzór:

$$\bar{x}_w = \frac{1}{n} \left[(k+1)x_{(k+1)} + \sum_{i=k+2}^{n-k-1} x_i + (k+1)x_{(n-k)} \right]$$

n – liczebność próby,

k – liczba modyfikowanych obserwacji z każdej strony uporządkowanego zbioru,

x_i – i -ta uporządkowana obserwacja.

To miara statystyczna, która ogranicza wpływ wartości skrajnych poprzez ich zastąpienie najbliższymi wartościami z pozostałej części danych. Pozwala to ocenić, czy dane są jednorodne oraz jak bardzo wyniki odstające wpływają na średnią. Jeśli średnia winsorowska niewiele się zmienia przy zwiększaniu k , oznacza to, że dane mają niewielkie wahania. W dalszej części pracy pokazano wykresy zależności średniej winsorowskiej od k , które przedstawiają wpływ liczby modyfikowanych obserwacji na wynik.

Obliczono średnie winsorowskie dla $k \approx 10\% \cdot n$ dla obu grup:

Grupa po kursie przygotowawczym, $k = 36$:

$$\bar{x}_w = \frac{1}{358} \left[(36+1)x_{(36+1)} + \sum_{i=36+2}^{358-36-1} x_i + (36+1)x_{(358-36)} \right] = 69.782122$$

Grupa bez kursu przygotowawczego, $k = 64$:

$$\bar{x}_w = \frac{1}{642} \left[(64+1)x_{(64+1)} + \sum_{i=64+2}^{642-64-1} x_i + (64+1)x_{(642-64)} \right] = 64.350467$$

Średnia winsorowska w obu grupach jest bardzo zbliżona do średniej arytmetycznej i ucinanej, co potwierdza brak znaczących wartości odstających. Jednocześnie nadal widać różnicę między grupami, co wskazuje, że uczniowie po kursie osiągają nieco wyższe wyniki niezależnie od sposobu liczenia średniej.

Kwartyle.

$Q2$ – mediana,

$Q1$ – mediana grupy obserwacji mniejszych od $Q2$,

$Q3$ – mediana grupy obserwacji większych od $Q2$.

Kwartyle dzielą zbiór na 4 grupy. Kwartył pierwszy ($Q1$) mówi o tym, że 25% danych ma wartości mniejsze lub równe $Q1$. Analogicznie kwartył trzeci ($Q3$) pokazuje od jakiej wartości 75% danych jest mniejsze lub równe.

Wyznaczono $Q1, Q2, Q3$ dla obu analizowanych grup:

Grupa po kursie przygotowawczym:

$$Q1 = 60,$$

$$Q2 = 69,$$

$$Q3 = 79.$$

Grupa bez kursu przygotowawczego:

$$Q1 = 54,$$

$$Q2 = 64,$$

$$Q3 = 75.$$

Wszystkie obliczone kwartyle są nieco wyższe dla wyników uczniów po kursie przygotowawczym, co wskazuje na ogólną poprawę wyników na całym rozkładzie, a nie tylko w jego wybranych fragmentach. Sugeruje to pozytywny wpływ kursu na przygotowanie do egzaminu bez względu na uzyskany wynik.

IQR (rozstęp międzykwartyłowy). Wzór:

$$IQR = Q3 - Q1$$

$Q1$ – pierwszy kwartył,

$Q3$ – trzeci kwartył.

Rozstęp międzykwartyłowy opisuje zróżnicowanie środkowych 50% danych oraz pozwala ocenić jak bardzo są skoncentrowane wokół mediany. Na jego podstawie można wnioskować o stopniu rozproszenia typowych wartości w zbiorze danych.

Obliczono IQR dla obu analizowanych grup:

Grupa po kursie przygotowawczym:

$$IQR = Q3 - Q1 = 79 - 60 = 19$$

Grupa bez kursu przygotowawczego:

$$IQR = Q3 - Q1 = 75 - 54 = 21$$

Wyniki uczniów po kursie przygotowawczym mają nieznacznie mniejszą wartość IQR , co oznacza, że zróżnicowanie 50% środkowych wyników jest bardzo podobne. Uczniowie w obu grupach osiągają podobnie rozproszone wyniki w zakresie typowych wartości.

Wariancja z próby. Wzór:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

n – liczebność próby,

x_i – i-ta obserwacja w zbiorze danych,

$\bar{x}$ – średnia arytmetyczna próby.

Odchylenie standardowe. Wzór:

$$s = \sqrt{\frac{\sum (x_i - \bar{x})^2}{n-1}}.$$

n – liczebność próby,

x_i – i-ta obserwacja w zbiorze danych,

$\bar{x}$ – średnia arytmetyczna próby.

Odchylenie przeciętne od wartości średniej. Wzór:

$$d = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|$$

n – liczebność próby,

x_i – i-ta obserwacja w zbiorze danych,

$\bar{x}$ – średnia arytmetyczna próby.

Współczynnik zmienności. Wzór:

$$\nu = \frac{s}{\bar{x}} \cdot 100\%$$

s – odchylenie standardowe z próby,

$\bar{x}$ – średnia arytmetyczna próby.

Współczynnik skośności (asymetrii). Wzór:

$$\alpha = \frac{n}{(n-1)(n-2)} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s} \right)^3$$

s – odchylenie standardowe z próby,

$\bar{x}$ – średnia arytmetyczna próby,

n – liczebność próby,

x_i – i-ta obserwacja w zbiorze danych,

Kurtoza. Wzór:

$$K = \frac{n-1}{(n-2)(n-3)} [(n+1)K_1 - 3(n-1)] + 3$$

$$K_1 = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4}{\left(\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \right)^2}$$

$\bar{x}$ – średnia arytmetyczna próby,
 n – liczebność próby,
 x_i – i -ta obserwacja w zbiorze danych,

Kurtoza to miara koncentracji uzyskanych wyników. Mówi czy i w jakim stopniu dane są skoncentrowane wokół średniej. Dla rozkładu normalnego kurtoza przyjmuje wartość 3, co stanowi punkt odniesienia przy interpretacji wyników.

Wyznaczono kurtozę dla obu analizowanych grup:

Grupa po kursie przygotowawczym:

$$K_1 = \frac{\frac{1}{358} \sum_{i=1}^{358} (x_i - 69.695530)^4}{\left(\frac{1}{358} \sum_{i=1}^{358} (x_i - 69.695530)^2\right)^2} = 2.821198$$

$$K = \frac{358 - 1}{(358 - 2)(358 - 3)} [(358 + 1)K_1 - 3(358 - 1)] + 3 = 2.835624$$


Grupa bez kursu przygotowawczego:

$$K_1 = \frac{\frac{1}{642} \sum_{i=1}^{642} (x_i - 64.077881)^4}{\left(\frac{1}{642} \sum_{i=1}^{642} (x_i - 64.077881)^2\right)^2} = 3.388875$$

$$K = \frac{642 - 1}{(642 - 2)(642 - 3)} [(642 + 1)K_1 - 3(642 - 1)] + 3 = 3.401325$$

Drobna różnica w wartościach kurtozy dla obu grup wskazuje na nieznacznie odmienny kształt rozkładów, jednak w obu przypadkach wartości pozostają w pobliżu poziomu charakterystycznego dla rozkładu normalnego. Wartość kurtozy o drobinę niższa od 3 dla grupy po kursie wskazuje, że rozkład wyników jest nieco bardziej spłaszczony niż rozkład normalny. Oznacza to mniejszą koncentrację wyników wokół średniej oraz mniejszą obecność wartości odstających. Wartość o drobinę wyższa od 3 dla grupy bez kursu oznacza, że rozkład jest bardziej skupiony wokół średniej, jednocześnie częściej pojawiają się wartości skrajne.


3 Prezentacja rozkładów na wykresach



Rysunek 1: Histogramy ukazujące liczbę osób oraz punktację jaką uzyskały z testu końcowego dla grupy po kursie przygotowawczym (po lewej) oraz bez (po prawej).


Na wykresie widac, że szczyt drugiego wykresu jest lekko przesunięty w prawą stronę w porównaniu z niebieskim wykresem. Potwierdza to nasze obliczenia oraz wnioski dotyczące średnich. Fakt, że średnie ucinana i winsorowska są podobne do arytmetycznej, mówi nam,

że sukces jest realny dla większości, nie tylko dla kilku osób. Wychodzącą ze wzorów powyżej ujemną skośność potwierdza wykres po prawej stronie, posiadający lewostronny ogon. Kształt rozkładu, opisany przez kurtozę oraz skośność, pokazuje, że wyniki po kursie częściej kumulują się w górnych granicach przedziałów, co widać po 'pogrubionym' prawym boku wykresu.



Rysunek 2: Histogram (opisany powyżej) z nałożoną gęstością rozkładu normalnego (czerwona linia).


Jak widać na powyższych histogramach, mają one podobne rozkłady, bardzo zbliżone do rozkładu normalnego. Jednak wykres po prawej stronie jest przesunięty w prawo. Linia rozkładu normalnego idealnie obrazuje nam to przesunięcie.



Rysunek 3: Wykresy pudełkowe z zaznaczonymi wartościami odstającymi oraz średnimi

Prezentowany wykres pudełkowy pokazuje różnice między dwoma badanymi grupami. Na pierwszy rzut oka widać, że kurs przygotowawczy podniósł wyniki z testu. Najbardziej dostrzegalne są linie średnich wyników. Niebieska linia jest zdecydowanie wyżej niż linia czerwona, co potwierdza nasze obliczenia. Niebieski boxplot jest wyraźnie krótszy niż różowy, co znajduje bezpośrednie potwierdzenie w wartościach wariancji oraz IQR. W grupie bez kursu wyniki są rozproszone, panuje tu duża niepewność i wysoki współczynnik zmienności. W grupie bez kursu obserwujemy długi dolny wąs oraz liczne wartości odstające, co wizualnie odpowiada ujemnej skośności rozkładu. Pokazuje to, że bez przygotowania ryzyko uzyskania bardzo niskiego wyniku jest wysokie. Kurs przygotowawczy minimalne wartości zostały drastycznie podciągnięte

w górę. Dzięki temu nawet najslabsi uczniowie w grupie po kursie osiągają wyniki zbliżone do średniej grupy nieprzygotowanej. Nie obserwujemy też dużo wartości odstających.



Rysunek 4: Zależność średnich od parametru k dla dwóch grup: po kursie (po lewej) oraz bez kursu (po prawej).

Na podstawie wykresów wyciągnięto wnioski. Średnia arytmetyczna jest wyższa od mediany w obu przypadkach, co mówi o dużej ilości wysokich wyników (rozkład prawostronnie skośny). Różnica między nimi w przypadku lewego wykresu wynosi 0.695530, co wskazuje na lekką asymetrię, natomiast prawego 0.077881, co jest mniejszą różnicą i sugeruje bardziej symetryczny rozkład. Pomarańczowa linia na lewym wykresie początkowo rośnie wraz z k , co sugeruje, że pierwsze usuwane obserwacje to pojedyncze niskie wartości, które zaniżały obraz grupy po kursie. Na prawym wykresie ten początkowy wzrost jest bardziej stromy, co może oznaczać więcej "niepowodzeń" (bardzo niskich wyników) w grupie bez przygotowania.

4 Wnioski